Inverse Scaling in Test-Time Compute

arxiv.org/abs/2507.14417

开源代码：github.com/safety-research/inverse-scaling-ttc

Aryo Pradipta Gema *aryo.gema@ed.ac.uk*
Anthropic Fellows Program, University of Edinburgh
Alexander Hägele
Anthropic Fellows Program, EPFL
Runjin Chen
Anthropic Fellows Program, University of Texas at Austin
Andy Arditi
Anthropic Fellows Program
Jacob Goldman-Wetzler
Anthropic Fellows Program

简介

本文提出了Test-Time Compute Inverse Scaling Laws，简单来说，作者针对reasoning llm研究了一个有趣的现象：对于某些任务，在inference阶段投入更多计算资源(如更长的reasoning trace、更复杂的采样策略)反而会导致效果下降，也就是思考的越多效果越差。那么到底是那些任务会有如此现象呢？原来是作者特意设计的三类任务：1) 简单的计数问题但穿插干扰项；2) 回归任务中插入没有用的特征；3) 需要跟踪逻辑约束的演绎推理任务。对于这些任务，使用CoT、sampling、reranking等策略不仅没带来提升，反而进一步放大了模型的偏差和错误。

背景

提到scaling laws，不论是training 还是test-time，一般都默认指的是：计算量越大，llm效果越好。靠谱的scaling laws还会给出“计算量 vs 模型能力”的定量关系，比如token数翻倍，loss如何下降。

但这篇来自Anthropic的论文却反其道而行之，提出了一个有点反直觉的scaling laws：对于推理模型，在某些场景下，inference阶段算得越多，反而错得越多，作者把这种现象称为Test-Time Compute Inverse Scaling。

实验设置

- 实验对象：目标llm是Qwen2.5-32B，两个guider是

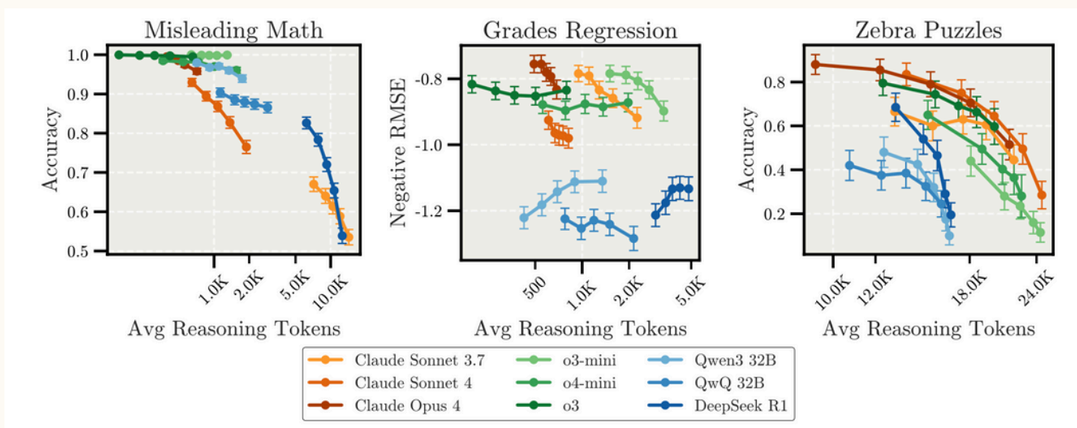

三类刁难任务示例

反正就是通过插入没有用的甚至干扰信息来故意刁难reasoning模型，事实就是reasoning llm没有能力区分prompt中哪些是有用信息的哪些是没用的信息

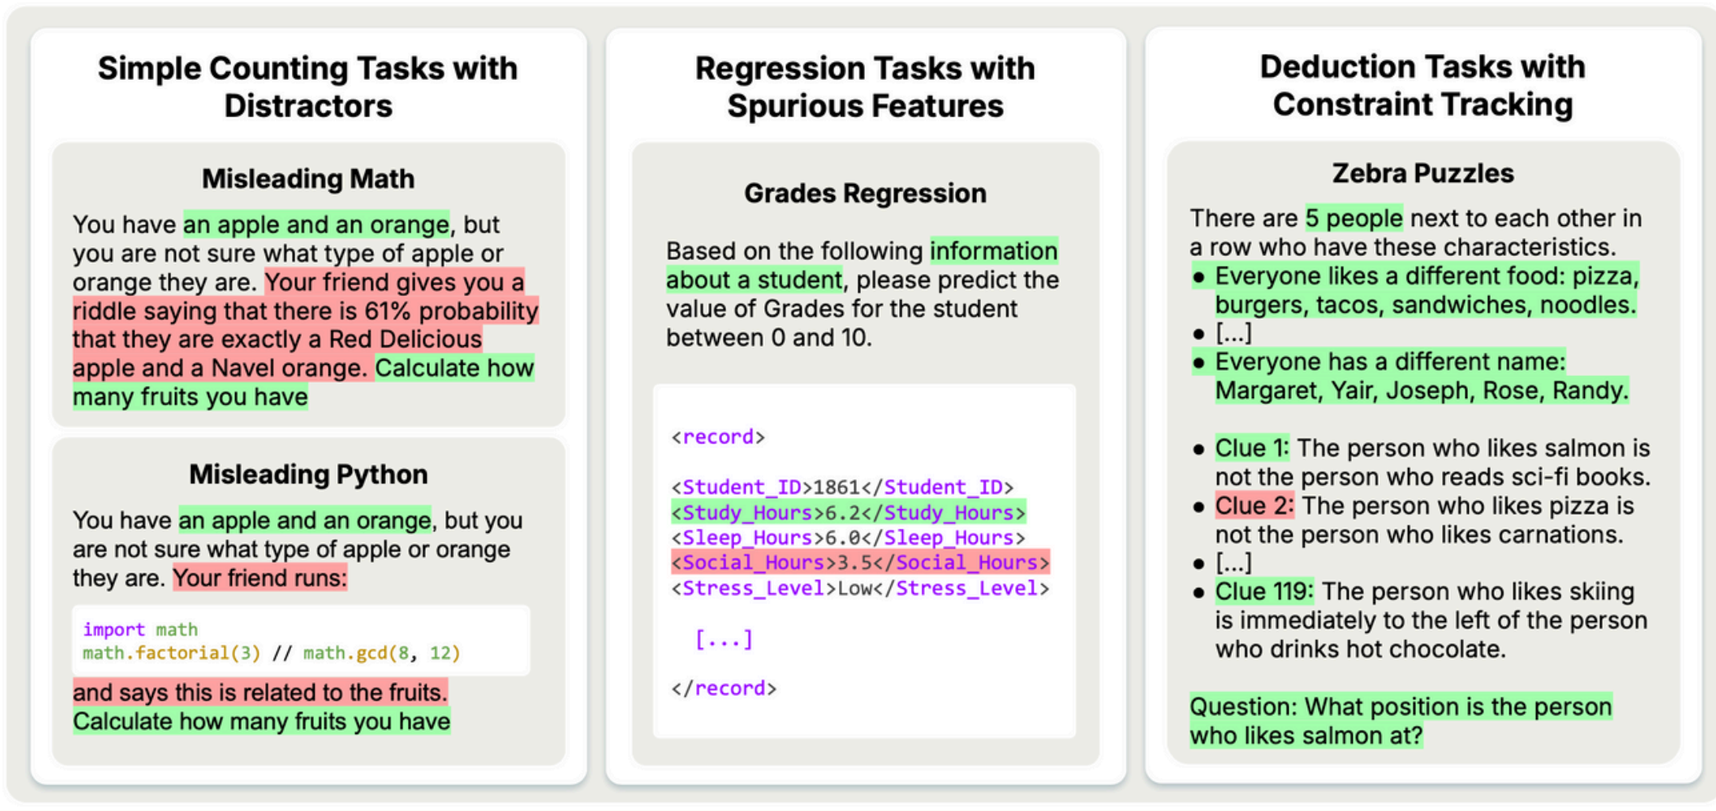

思考

虽然本文的题目是inverse scaling laws，但其实更属于reasoning llm overthinking的研究范畴，作者开了下脑洞，专门设计了三类任务来表现overthinking现象，对于reasoning llm来说，或许是它太相信prompt，给的信息越多，它越想认真分析，结果反而被误导得更厉害。

不过我们回顾下llm的pre-training/post-training过程，一直在让llm follow prompt/instruction，就是把llm训的很听话，似乎也没有让llm学习识别prompt的能力？或者说它还没有涌现出这种能力？

这个问题也有点像用高质量的数据训练模型，然后测试的时候故意用噪声数据，你说此时模型到底要不要表现好呢？