

R²EC: TOWARDS LARGE RECOMMENDER MODELS WITH REASONING

如何基于LLM构建统一的REASONING-THEN-RECOMMEND推荐模型？

开源代码：HTTPS://GITHUB.COM/YRYANGANG/RREC

Runyang You¹ Yongqi Li^{1*} Xinyu Lin² Xin Zhang¹

Wenjie Wang³ Wenjie Li¹ Liqiang Nie⁴

¹The Hong Kong Polytechnic University ²National University of Singapore

³University of Science and Technology of China ⁴Harbin Institute of Technology (Shenzhen)

runyang.y@outlook.com, liyongqi0@gmail.com,

xylin1028@gmail.com, zhangxin2023@stu.hit.edu.cn,

wenjiewang96@gmail.com, cswjli@comp.polyu.edu.hk, nieliqiang@gmail.com

简介

本文提出R2ec，一个基于LLM的统一推荐模型，模型先生成语言推理过程，再进行目标item推荐，通过将推理生成与推荐决策融合为一条推理轨迹，实现了Reasoning-then-Recommend。R2ec构建于一个共享backbone(LLM)的多任务框架之上，推理与推荐共享参数并协同训练，为实现有效训练，作者设计了多路径采样机制，所有路径参与推理模块更新，而只用优势最大的推理路径进行推荐head优化。

背景

如何借助LLM的推理能力提升推荐效果？目前主流做法通常是将语言推理与推荐任务分开处理，分别建模，难以进行统一优化，模型是否能真正学会“推理驱动推荐”，要打个问号。为此，本文提出 R2EC，将LLM推理和推荐两个差异很大的任务融合到同一个模型中，实现了“先推理，再推荐”（REASONING-THEN-RECOMMEND）的端到端训练。

实验设置

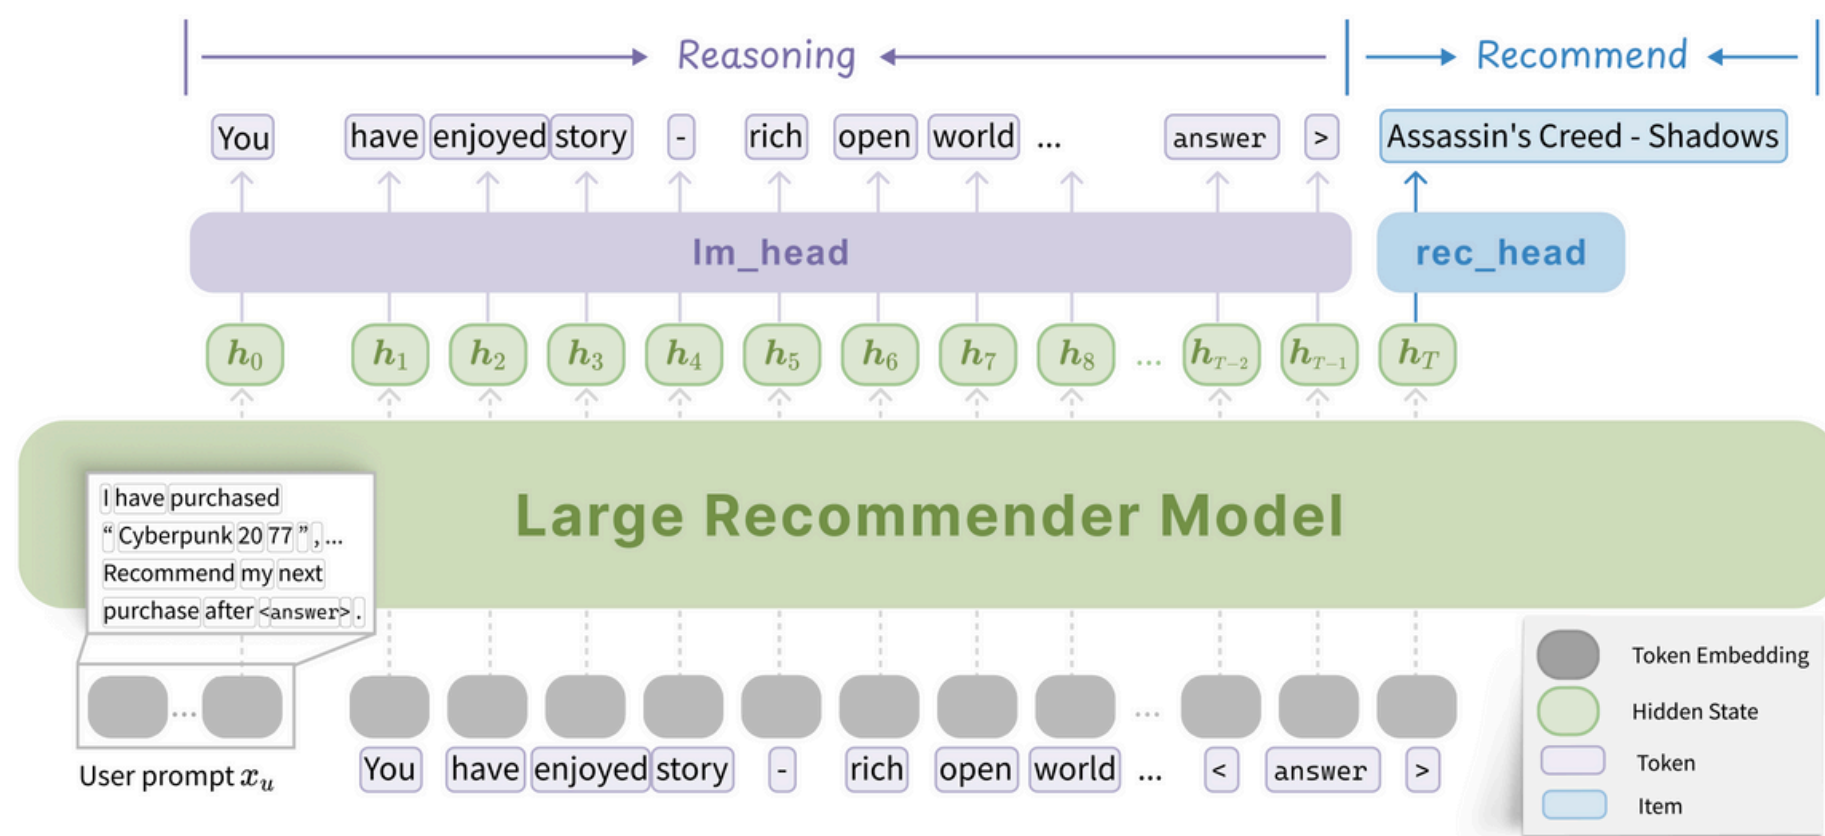
- RL框架：trl，RL算法：RecPO，LLM: Qwen2.5-3B-Instruct和Gemma-2-2b-it
- Reward function：包含NDCG和in-batch softmax两项。后者权重很小(0.05)

$$R_d = \text{NDCG} @k (\text{rank}(v^+))$$

$$R_c = \frac{\exp(\mathbf{h}_T^\top \mathbf{h}_{v^+} / \tau)}{\sum_{v \in \mathcal{V}} \exp(\mathbf{h}_T^\top \mathbf{h}_v / \tau)},$$

$$R = \beta R_c + (1 - \beta) R_d, \quad \beta \in [0, 1],$$

模型结构



USER和ITEM PROMPT

User Prompt

Analyze in depth and finally recommend next {category} I might purchase inside <answer> and </answer> . For example, <answer> a product </answer> .

Below is my historical {category} purchases and ratings (out of 5):

{% for hist in purchase_histories %}
{% {hist.time_delta} ago: [{hist.item_title}] ({hist.rating}) %}

Item Prompt

Summarize key attributes of the following {category} inside <answer> and </answer> :

{% for key, attr in item.meta %}
{% {key}: {attr} %}

训练过程

Algorithm 1 Training Process

Input: Dataset \mathcal{D} , initial policy π_θ , embedding function f_θ , item embedding table $\mathbf{H}_\mathcal{V}$

Output: Optimized policy model π_θ

```
1: for step = 1 to  $N$  do
2:   if step %  $T_{\text{refresh}}$  == 0 then
3:     Refresh item embedding:  $\mathbf{H}_\mathcal{V}[v] \leftarrow f_\theta(x_v), \quad \forall v \in \mathcal{V}$ 
4:   end if
5:   Sample a training batch  $\mathcal{B} = \{(u, v^+)\} \sim \mathcal{D}$ 
6:   Encode target item prompts and update embedding table:  $\mathbf{H}_\mathcal{V}[v^+] \leftarrow f_\theta(x_{v^+}) \quad \forall (u, v^+) \in \mathcal{B}$ 
7:   for all  $(u, v^+)$  in  $\mathcal{B}$  do
8:     Generate  $G$  trajectory:  $\{[o_1, v^+], \dots, [o_G, v^+]\} \sim \pi_{\theta_{\text{old}}}(\cdot | x_u)$ 
9:     Compute reward for each trajectory using Eq. (5)
10:    Compute advantage for each trajectory using Eq. (2)
11:  end for
12:  Update policy parameters  $\theta$  via loss in Eq. (8)
13:  Update old policy:  $\theta_{\text{old}} \leftarrow \theta$ 
14: end for
```

思考

很久不做推荐了，不太确定自己的理解是否准确。RREC的核心目标是训练一个LLM，能够先生成推理过程再进行推荐。简单来说，就是将推理轨迹中最后一个TOKEN的隐状态输入到推荐HEAD，用于预测目标ITEM。但LLM推理和推荐系统可是两个差异很大的任务，如何统一到同一个模型中进行训练呢？

作者设计了RECPO强化学习算法：首先采样多条推理路径，每条路径最后都推荐一个ITEM，然后分别计算融合奖励（推荐排序的NDCG分数 + 推理表示与目标ITEM的相似度），并据此估算每条路径的优势（ADVANTAGE）。所有路径都参与推理部分的训练，而推荐部分则仅使用优势最大的那条路径进行更新。